



UNIVERSIDAD TECNOLÓGICA DEL ORIENTE

Facultad de Ingeniería · Programa de Ingeniería de Software

Asignatura: Inteligencia Artificial

Diseño de Algoritmos de Aprendizaje Profundo: Predicción de Precios de Vivienda mediante una Red Neuronal Densa

Caso de estudio: dataset California Housing

Elaborado por:

Ing. Carlos Carrascal

Docente — Ejemplo de referencia para la actividad (Aprendizaje Basado en Retos)

18 de julio de 2026

Resumen

Este trabajo presenta el diseño, la implementación y la evaluación de un algoritmo de aprendizaje profundo —una red neuronal densa (perceptrón multicapa)— para estimar el valor de las viviendas a partir de sus características socioeconómicas y geográficas, utilizando el conjunto de datos público California Housing (20.640 registros y 8 variables). El modelo, con una arquitectura de tres capas ocultas (128–64–32 neuronas), activación ReLU, regularización por Dropout y optimizador Adam, alcanzó un coeficiente de determinación R^2 de 0,821 sobre el conjunto de prueba, con un error absoluto medio (MAE) de 0,332 (aproximadamente 33.244 USD). Más allá del desempeño técnico, el estudio incorpora una evaluación ética de la equidad del modelo, demostrando que el uso de la ubicación geográfica —aunque mejora la predicción en 10,1 puntos de R^2 — constituye una variable sensible que puede reproducir sesgos socioeconómicos por barrio. Se concluye que el aprendizaje profundo es una herramienta eficaz para la valoración automática de inmuebles, siempre que su despliegue vaya acompañado de auditorías de equidad.

Palabras clave: aprendizaje profundo, red neuronal densa, regresión, predicción de precios, equidad algorítmica, California Housing.

1. Identificación y Justificación del Problema

Determinar si el precio de una vivienda es justo es un problema cotidiano con consecuencias económicas relevantes. Compradores, vendedores, entidades bancarias y aseguradoras necesitan estimar el valor de un inmueble a partir de sus atributos; una valoración errónea puede derivar en pérdidas económicas, en créditos hipotecarios mal otorgados o en decisiones de inversión equivocadas. Este es, por lo tanto, un problema real, actual y de alto impacto.

La valoración automática de inmuebles (Automated Valuation Models) se ha convertido en un área de investigación muy activa. Trabajos recientes muestran que los modelos de aprendizaje automático superan a la regresión lineal clásica en esta tarea, y que las arquitecturas de aprendizaje profundo permiten integrar múltiples fuentes de información —atributos estructurales, imágenes y datos geoespaciales— para mejorar la precisión (Hasan et al., 2024; Zhang et al., 2024). El interés industrial y académico sostenido justifica abordar el problema con técnicas modernas.

Se selecciona este problema por su relevancia práctica y porque constituye un caso de regresión idóneo para ilustrar el diseño de una red neuronal profunda: las relaciones entre el ingreso de la zona, la antigüedad, el número de habitaciones y la ubicación son no lineales y presentan interacciones que un modelo lineal no captura adecuadamente. La necesidad de una solución innovadora surge, además, de un aspecto crítico: al incorporar variables geográficas, el modelo puede discriminar por zona o barrio, un riesgo ético que este trabajo evalúa de manera explícita.

2. Revisión Bibliográfica

La revisión se apoya en literatura reciente (2021–2026) sobre tres ejes: fundamentos del aprendizaje profundo, su aplicación a la valoración inmobiliaria y la equidad algorítmica.

2.1. Fundamentos del aprendizaje profundo

Sarker (2021) ofrece una taxonomía integral de las técnicas de aprendizaje profundo y subraya el papel de las redes neuronales multicapa como aproximadores universales de funciones, aplicables a datos tabulares. Janiesch et al. (2021) diferencian el aprendizaje automático del profundo y explican por qué las redes neuronales, al aprender representaciones jerárquicas, resultan especialmente adecuadas para problemas con relaciones complejas. Estos aportes fundamentan la elección de un perceptrón multicapa y de funciones de activación no lineales (ReLU) para el presente trabajo.

2.2. Aprendizaje profundo aplicado a la valoración de vivienda

Hasan et al. (2024) proponen un enfoque multimodal que combina imágenes y atributos del inmueble mediante redes convolucionales y de regresión profunda, superando a los métodos tradicionales. Zhang et al. (2024) introducen redes de grafos temporales con meta-aprendizaje por transferencia para la tasación entre ciudades, evidenciando la importancia del componente espacial. Wang, J. et al. (2025) optimizan una red neuronal con algoritmos genéticos y de enjambre para predecir precios de vivienda de segunda mano, mientras que Wang, S. et al. (2025) publican un conjunto de datos espaciotemporal a gran escala para estandarizar la evaluación de estos modelos. Tanashkin et al. (2025) advierten sobre la necesidad de construir modelos interpretables en la valoración catastral masiva. En conjunto, esta literatura respalda el uso de redes densas y confirma que la ubicación es un predictor determinante —y a la vez delicado— del precio.

2.3. Equidad y sesgos algorítmicos

Mehrabi et al. (2021) y Pessach y Shmueli (2022) sistematizan las fuentes de sesgo en el aprendizaje automático y las definiciones formales de equidad, alertando sobre las variables 'proxy' que codifican de forma indirecta atributos protegidos. Fabris et al. (2022) documentan los conjuntos de datos empleados en la investigación sobre equidad y sus limitaciones. Esta línea es central para el presente estudio: la latitud y la longitud pueden actuar como proxy del nivel socioeconómico, por lo que su uso exige una evaluación de equidad como la que se desarrolla en la Sección 5.

3. Diseño del Algoritmo

El conjunto California Housing contiene 20.640 registros, cada uno correspondiente a un grupo de manzanas de California, descrito por ocho variables: ingreso medio (MedInc), antigüedad de la

vivienda (HouseAge), promedio de habitaciones (AveRooms) y de dormitorios (AveBedrms), población (Population), ocupación media (AveOccup), latitud y longitud. La variable objetivo es el valor medio de la vivienda, expresado en cientos de miles de dólares.

3.1. Preprocesamiento

Los datos se dividieron en tres subconjuntos: 70 % para entrenamiento (14.448 registros), 15 % para validación y 15 % para prueba (3.096 registros). Todas las variables se estandarizaron (media 0 y desviación 1) con un escalador ajustado únicamente sobre el conjunto de entrenamiento, para evitar la fuga de información. La estandarización es necesaria porque las variables presentan escalas muy dispares y ello estabiliza el descenso de gradiente (Sarker, 2021).

3.2. Arquitectura de la red neuronal densa

Cada decisión de diseño se justifica en la literatura revisada y en la naturaleza del problema, según se resume en la Tabla 1.

Componente	Elección	Justificación
Capas ocultas	3 densas (128–64–32)	Profundidad suficiente para relaciones no lineales sin sobreajuste
Activación	ReLU	Evita el desvanecimiento del gradiente (Sarker, 2021)
Regularización	Dropout (0,2)	Reduce el sobreajuste desactivando neuronas al azar
Capa de salida	1 neurona lineal	Regresión: predice un valor continuo
Función de pérdida	Error cuadrático medio (MSE)	Penaliza con fuerza los errores grandes
Optimizador	Adam (lr = 0,001)	Convergencia rápida y estable
Métrica	Error absoluto medio (MAE)	Interpretable en la unidad del precio
Parada temprana	EarlyStopping (paciencia 15)	Detiene el entrenamiento al dejar de mejorar la validación

Tabla 1. Arquitectura de la red neuronal densa y justificación de cada decisión de diseño.

4. Implementación y Pruebas

El modelo se implementó en Python con la biblioteca TensorFlow/Keras y se ejecutó en el entorno Google Colab. Antes del modelado se realizó un análisis exploratorio de los datos. La Figura 1 muestra la distribución del precio —sesgada a la derecha y con un tope artificial en 500.000 USD por censura del censo— y la matriz de correlación, donde el ingreso medio (MedInc) es la variable más correlacionada con el precio.




Figura 1a. Distribución del valor medio de la vivienda.




Figura 1b. Matriz de correlación entre variables.




Figura 2. Precio de la vivienda según la ubicación geográfica en California. Se observa que las zonas costeras concentran los valores más altos.

El entrenamiento se detuvo automáticamente cerca de la época 95 gracias a la parada temprana, que monitorea la pérdida de validación. La Figura 3 muestra la curva de aprendizaje: la pérdida desciende de forma estable y se estabiliza, sin señales de sobreajuste.




Figura 3. Curva de aprendizaje de la red neuronal (descenso de la pérdida MSE).

Sobre el conjunto de prueba (datos nunca vistos por el modelo), se obtuvieron los resultados de la Tabla 2. El modelo explica el 82,1 % de la variabilidad del precio, con un error promedio cercano a 33.000 USD, un desempeño sólido para un problema de esta complejidad.

Métrica	Valor	Interpretación
MAE	0,332	Error promedio $\approx$ 33.244 USD
RMSE	0,486	Penaliza más los errores grandes
R ²	0,821	82,1 % de la varianza explicada

Tabla 2. Desempeño del modelo sobre el conjunto de prueba.

La Figura 4 compara los valores predichos con los reales: la nube de puntos se agrupa en torno a la diagonal ideal, confirmando un buen ajuste. La franja vertical en el extremo superior corresponde al tope censurado de 500.000 USD, donde el modelo tiende a subestimar.




Figura 4. Valores predichos frente a valores reales en el conjunto de prueba.

A modo de prueba práctica, para una vivienda de ejemplo el modelo predijo 80.324 USD frente a un valor real de 100.000 USD, un error coherente con el MAE global.

5. Evaluación y Reflexión (Aspectos Éticos y de Equidad)

El desempeño técnico no basta para considerar el modelo apto: es preciso evaluar su equidad. Se analizaron dos riesgos derivados del uso de la ubicación geográfica.

5.1. Equidad según el nivel socioeconómico

Se calculó el error absoluto medio del modelo separando las zonas por nivel de ingreso (bajo, medio y alto). Como muestra la Figura 5, el error es menor en las zonas de ingreso bajo (0,270) y mayor en las de ingreso alto (0,392). Este comportamiento se explica, en parte, por el tope censurado del precio y por la mayor variabilidad de las viviendas costosas; no obstante, evidencia que la calidad de la predicción no es uniforme entre grupos, lo que debe vigilarse si el modelo se usara en decisiones sensibles (Mehrabi et al., 2021).




Figura 5. Error absoluto medio del modelo según el nivel de ingreso de la zona.

5.2. Peso de la ubicación como variable 'proxy'

Para medir cuánto depende el modelo del 'barrio', se entrenó una segunda red neuronal idéntica pero eliminando la latitud y la longitud. El R^2 descendió de 0,821 a 0,720; es decir, la ubicación aporta 10,1 puntos de R^2 . Esto confirma que la posición geográfica es un predictor potente, pero también que actúa como variable proxy del nivel socioeconómico. En un uso real —por ejemplo, para aprobar créditos— esta dependencia podría traducirse en un 'redlining algorítmico', negando sistemáticamente oportunidades a ciertos barrios (Pessach y Shmueli, 2022; Fabris et al., 2022).

5.3. Limitaciones y mejoras futuras

El estudio presenta limitaciones: los datos provienen del censo de 1990 y no reflejan el mercado actual; el análisis se realiza sobre grupos de manzanas y no sobre viviendas individuales; y el modelo depende fuertemente de la ubicación. Como líneas de mejora se proponen: (a) emplear datos actuales y desagregados; (b) auditar la equidad de forma periódica; (c) incorporar técnicas de explicabilidad como SHAP para interpretar cada predicción; (d) explorar arquitecturas y enfoques multimodales (Hasan et al., 2024); y (e) aplicar métodos de mitigación de sesgos cuando el modelo se destine a decisiones de alto impacto.

6. Conclusiones

Se diseñó, implementó y evaluó una red neuronal densa capaz de predecir el precio de la vivienda con un R^2 de 0,821 y un error promedio cercano a 33.000 USD, superando a los enfoques lineales tradicionales gracias a su capacidad de modelar relaciones no lineales. Más importante aún, el trabajo demuestra que un buen desempeño técnico debe acompañarse de una evaluación ética: la ubicación geográfica, pese a mejorar la predicción, introduce un riesgo real de discriminación por barrio. Se concluye que el aprendizaje profundo es una herramienta poderosa para la valoración automática de inmuebles, siempre que su despliegue responsable incluya auditorías de equidad, transparencia y vigilancia continua de los sesgos.

Referencias

- Fabris, A., Messina, S., Silvello, G., & Susto, G. A. (2022). Algorithmic fairness datasets: The story so far. *Data Mining and Knowledge Discovery*, 36, 2074–2152.
<https://doi.org/10.1007/s10618-022-00854-z>
- Hasan, M. H., Jahan, M. A., Ali, M. E., Li, Y.-F., & Sellis, T. (2024). *A multi-modal deep learning based approach for house price prediction*. arXiv. <https://arxiv.org/abs/2409.05335>
- Janiesch, C., Zschech, P., & Heinrich, K. (2021). Machine learning and deep learning. *Electronic Markets*, 31(3), 685–695. <https://doi.org/10.1007/s12525-021-00475-2>
- Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. *ACM Computing Surveys*, 54(6), 1–35.
<https://doi.org/10.1145/3457607>
- Pessach, D., & Shmueli, E. (2022). A review on fairness in machine learning. *ACM Computing Surveys*, 55(3), 1–44. <https://doi.org/10.1145/3494672>
- Sarker, I. H. (2021). Deep learning: A comprehensive overview on techniques, taxonomy, applications and research directions. *SN Computer Science*, 2, Artículo 420.
<https://doi.org/10.1007/s42979-021-00815-1>
- Tanashkin, A. S., Tanashkina, I. G., & Maksimchuk, A. S. (2025). *Modern approaches to building interpretable models of the property market using machine learning on the base of mass cadastral valuation*. arXiv. <https://arxiv.org/abs/2506.15723>
- Wang, J., Ji, H., & Wang, L. (2025). Forecasting second-hand house prices in China using the GA-PSO-BP neural network model. *PLoS ONE*, 20(5), e0322821.
<https://doi.org/10.1371/journal.pone.0322821>
- Wang, S., Sun, Y., Chen, F., Wang, L., Ramakrishnan, N., Lu, C., & Chen, Y. (2025). *HouseTS: A large-scale, multimodal spatiotemporal U.S. housing dataset and benchmark*. arXiv.
<https://arxiv.org/abs/2506.00765>
- Zhang, W., Han, J., Liu, H., Fan, W., Wang, H., & Xiong, H. (2024). *Meta-transfer learning powered temporal graph networks for cross-city real estate appraisal*. arXiv.
<https://arxiv.org/abs/2410.08947>